

ASIC 调研:字节 Ada1/2 进展,腾讯 DSP 应用场景,智谱端侧芯片定位-聚焦字节/阿里/腾讯/寒武纪/沐曦/智谱等

2026/07/21 10:59

要点

- 1、字节 Ada1/2 进展;
- 2、腾讯 DSP 应用场景;
- 3、智谱端侧芯片定位。

以下为专家观点:

请介绍一下字节自研芯片（例如 Ada1、Ada2）的最新进展？

字节的自研芯片是针对特定应用场景的专用芯片，其开发有两个前提：首先，单一应用场景的使用量必须足够大；其次，算法模型需相对固定，即未来一到两年内的算法改进方向是明确且变动不大的，这样硬件设计才能与软件和模型紧密配合，从而实现成本节约。若算法改动过大导致硬件不适配，则无法达到降本目的。当前自研的 Ada 系列芯片，其应用场景被严格限定在生成式视频模态的推理工作上。在这两个特定条件下，该芯片能够显著降低成本，但在其他应用场景下则不具备成本优势。这一定位决定了它与外采芯片的区别。外采芯片用于不同的场景：例如，与寒武纪的合作主要集中在“豆包”等 NLP 应用，即纯文本或图片相关的场景；而英伟达的 H100 等产品则主要用于视频模态的模型训练环节。即使在无法采购 H100 而需要降级方案的情况下，自研的 Ada 芯片也因场景不匹配而无法使用。因此，其核心区别在于应用场景的划分。

Ada1 和 Ada2 的性能分别对标英伟达的哪款产品？与对标产品存在性能差距的主要原因是什么？

在生成式视频推理这一特定测试环境下，Ada1 的性能可以达到英伟达 H100 的 70%至 80%。Ada2 的目标是达到 H200 性能的 70%。性能差距的主要原因在于硬件配置的权衡。作为一款专用芯片，其产品生命周期通常只有一到两年就会被迭代，因此为其配备顶级的 HBM 在成本上并不划算。HBM 集成在芯片中，当芯片被淘汰时无法复用。

除了为字节提供芯片代工服务外，公司还与其他哪些厂商有合作？与腾讯的具体合作项目和进展如何？

除字节外，目前合作体量较大的客户是阿里，其次是腾讯。与腾讯的合作于 2026 年刚刚起步，合作规模尚不大。当前主要为腾讯提供两款产品的服务：一款是用于过渡的 DSP 芯片，另一款是网关卡。不过，相较于阿里和字节，腾讯在自研芯片方面的整体进度以及与公司的

合作节奏都相对较慢。

关于为腾讯开发的 DSP 芯片，其具体功能和定位是什么？

此处的 DSP 并非光模块中使用的电芯片，其定位更接近于数据处理芯片。这款 DSP 的区别在于，它在处理模型文件时，仅负责推理过程中的部分工作，即 Prefill 阶段，后续的解码阶段则不涉及，客户可以采用 GPU 或其他通用及专用芯片完成剩余工作。因此，该 DSP 芯片仅能执行部分的推理任务。

针对 Ada1 项目，2027 年的量产合作在单价和利润率方面预计会有哪些变化？

预计 2027 年的量产合作中，单颗芯片的成本会有所浮动。其中，量产管理费的变动可能不大，而公司在该项费用中的利润率或有提升空间。成本浮动较大的部分将是存储采购费用，主要因为无法准确预测 2027 年 HBM 存储芯片的价格走势是上涨还是下跌。

从成本角度看，字节自研芯片相较于外购方案（如寒武纪、华为）具有显著优势，未来将如何平衡自研与外购的比例和节奏？

关键在于必须明确应用场景的规模和未来的算法迭代方向。只有在这两点都明确的情况下，自研才具备可行性。尽管当前自研芯片成本较低，但如果一年后算法或应用场景发生变化，这款高度适配当前场景的芯片可能会因为不再适用而报废，导致大规模投入的浪费。因此，只有对未来算法发展方向和应用场景有足够信心和准确判断时，才会大规模量产自研芯片。目前，字节的自研芯片主要限定在视频生成和推理这一特定场景。

在视频处理场景中，与华为和寒武纪的方案相比，字节的自研芯片有何差异？

寒武纪目前明确只供给豆包大模型场景。字节曾与寒武纪探讨过视频场景的合作，但由于寒武纪提出的改进周期长达两年，字节最终未采纳其方案。华为的方案虽然能够满足视频处理的需求，但其综合成本，包括电力使用和制造成本，要高出一个数量级。

近期观察到智谱也开始自研芯片，这背后的行业趋势和具体情况是怎样的？

行业整体趋势判断是，2025 至 2027 年市场以云端 AI 芯片为主，但在 2028 年前后，端侧 AI 芯片将迎来一波爆发式增长。其逻辑在于，云端的应用场景成熟后，最终都会在端侧找到落


调研纪要

微信扫码加入星球

知识星球

星球福利

微信扫码
联系客服加入



地应用。特别是在制造业和高端服务业（如医疗）等对 IO 时延要求极高的场景，必须部署端侧模型。具体到近期市场需求，以浪潮服务的政府和大型国企为例，这些单位希望利用大模型辅助工作，但出于数据安全考虑，不能将数据上传至公有云，因此需要进行本地化部署。消费级显卡无法满足此需求，需要自建服务器。这类项目需求是将消费级显卡进行二次设计，主要改造散热和封装，以适应单位内部服务器的需求，其设计周期相对较短。

智谱在端侧大模型应用方面有何布局，这将如何影响芯片设计需求？

智谱的应用场景正拓展至制造业，通过部署本地大模型，使机械臂能够替代以往必须由人工完成的实时判断环节。传统的云端模型因数据往返延迟，无法满足工业流水线的即时性要求。随着本地大模型技术的应用，机械臂将具备自主判断能力。预计从 2027 年开始，智谱将在此领域发力。这一趋势将推动每个工厂部署端侧服务器及本地大模型。在此模式下，智谱负责软件和基础模型，而芯片设计公司需要提供基础芯片，并针对每个工厂的本地化部署进行设计优化，以适应其软件和模型的调整。这预示着端侧应用将迎来爆发式增长。

寒武纪在三星的芯片产能情况如何，寒武纪在与三星合作中面临哪些具体挑战？

寒武纪在三星的产能较少。尽管产能数字可观，但合作面临严苛条件。首先，寒武纪自身的技术标准与三星的工艺标准不兼容，在 2027 年合作初期会导致良率极低。相比之下，三星现有工艺是基于新标准优化的，良率可达 78%-80%。其次，产能爬坡过程将是缓慢的，初期需要不断对接和调试各项标准，难以立即实现大规模量产。为在一年内将良率提升至理想水平，寒武纪可能需要派驻一支约两三百人的团队常驻三星进行技术攻关，否则仅凭十几人的团队可能需要三至四年时间。

公司与台积电的合作模式是怎样的，为何更倾向于选择三星作为主要合作伙伴？

公司与台积电的合作较少，主要集中在汽车芯片领域，例如之前曾与地平线有过合作。通常情况下，公司不倾向于与台积电合作，主要原因是三星与台积电的工艺标准在某种程度上不兼容。为台积电的工艺设计一套完全不同的标准，需要投入的成本过高，因为必须全面兼容台积电的标准，而无法让其兼容公司标准。因此，除非特殊情况，公司会优先选择三星。汽车芯片领域是一个例外。部分车企客户，如地平线，其芯片方案从一开始就是基于台积电的标准设计的。在这种情况下，若要承接其设计业务，沿用台积电的设计标准反而成本相对较低。对于这类项目，公司通常只负责设计阶段，完成设计后由客户自行负责量产管理。不过，与理想汽车的合作是一个特例，合作深度更广。

寒武纪在产能分配中是否同时通过与字节合作及独立渠道两部分来获取，合计份额大概是多

少？

是的，寒武纪获取产能的方式包括与字节合作以及独立获取两部分，合计份额差不多能占到 10%到 20%。

字节对 2027 年向寒武纪和华为的芯片采购需求有何预估？

字节明确计划在 2027 年采购寒武纪的 590 和 690 芯片，其需求缺口预计在 100 万颗到 300 万颗之间。对于华为的芯片，预计 2027 年的采购量会比 2026 年更少。主要原因是华为芯片的定价较高。由于华为自身产能紧张，其对外销售的芯片价格会更高。

华为 2027 年 950 系列芯片（包括 PR 和 DT 版本）的总产能预计有多少，其中自用比例如何？

综合考虑 2027 年上半年的扩产前产能和下半年的扩产后产能，预计华为 950 系列芯片全年的总产能大约在 300 万到 400 万颗。其中，华为自身至少会使用一半的产能。

字节、腾讯等公司在采用华为芯片时，是否存在对潜在竞争关系的顾虑，以及如何应对？

确实存在顾虑。这种顾虑是公开的，主要担心华为是否会利用其制定的硬件标准，在表面看不出差异的情况下，提供性能较低的硬件，而自用性能更优越的版本，从而导致在同一标准下，自身的训练效率低于华为。为应对这种顾虑，这些公司会进行环节区分。在核心或重要环节，倾向于使用自研芯片，或采购英伟达、寒武纪等不存在直接竞争关系的厂商产品。而华为的芯片则可能被用在一些顾虑较小或可随时被替代的环节。因此，虽然存在顾虑，但可以通过采取一定的应对措施来管理风险。

字节旗下豆包业务对寒武纪芯片的需求缺口高达 100 万至 300 万颗，远超寒武纪可获得的产能，这一供需矛盾将如何解决？是否有替代方案？

需求确实存在，如果 2027 年无法满足全部供应，那么未满足的需求将顺延至 2028 年继续供给。替代方案是存在的，如果不计成本，可以直接采购英伟达的 GPU 卡。此外，公司自身也能提供相应的解决方案。

关于允许采购 NVIDIA H200 用于训练的政策，目前是否有具体的落地进展？

该政策正在落地过程中，例如字节已在和英伟达进行商谈。谈判的核心在于英伟达对其产品的“阉割”程度，即性能限制的水平。如果字节对最终的性能规格满意，便可能进行采购；反之，若不满意，则谈判无法继续。在此事中，价格是次要考虑因素，关键在于性能限制问题。

关于 DeepSeek 自研芯片项目的团队情况、时间规划及首款芯片定位是怎样的？

DeepSeek 的自研芯片团队位于杭州，目前仍在招聘阶段，团队规模约 20 余人。规划上，预计在 2027 年团队规模将扩充至 200 人左右。项目进展方面，第一代芯片会优先与半导体公司合作，若合作在 2026 年年底展开，预计可在 2028 年实现量产。关于首款芯片的定位，其设计理念类似于早期比特大陆为挖矿业务开发的专用矿卡，即用极低的功耗实现高效的特定任务处理。该芯片旨在针对中国市场的特定大模型进行深度优化，将模型算法固化，而不必像英伟达产品那样为未来算法迭代预留大量冗余。架构方面，虽然理论上属于 NPU 范畴，但它将脱离传统 NPU 架构，开发一种为特定大模型定制的专有架构，可以看作是 NPU 架构下的一个子类，但严格来说已不能称之为标准 NPU。