

大摩闭门会-多空交战，下半年半导体投资如何布局？

20260724

国产算力超节点化与存储驱动型 Capex 扩张研报摘要

摘要

- 国产AI芯片转向超节点架构,通过 Scale-Up 纵向扩展弥补单卡算力差距。华为 Atlas 950 实现 1,024 卡互联,算力达 1EFLOPS,采用正交架构与光电混合互联提升利用率。
- 单卡技术路径分化:天数智芯天垓 300 实测推理性能优于 H100;东方算星 DF1,000 通过 14nm+3D 堆叠实现 6.4TB/s 带宽,验证非先进制程绕开内存墙的可行性。
- 云厂商 Capex 大幅上修,但 30%-40%增量由存储涨价驱动。Google 服务器支出占比达 60%,其 TPU 组件采购价高出英伟达 40%-50%,自由现金流面临提前转负压力。
- CPU 市场供需两极分化:英特尔受益于价格上涨但增量有限;海光高端产品对标英特尔第六代服务器 CPU,受国产化政策驱动出货量高速增长,带动周边芯片需求。
- 存储行业周期预计 2026 年 Q3 见顶,Legacy NAND (MLC/SLC) 因供应下滑缺口达 40%,价格单季涨幅或超 50%。旺宏电子因毛利弹性被视为核心标的。
- 台积电 2nm 扩产超预期,1.4nm 将成最大节点。AI 半导体 2027 年市场规模预计增长 60%-70%,英特尔服务器 CPU 外包台积电被视为 1.4nm 节点最大增量机会。
- 英伟达放弃 Kyper 项目,转向多机架超节点架构,将显著增加服务器主板、电源及 BMC 组件需求。MediaTek 在谷歌 TPU 出货量预计达 300 万颗,份额直追博通。

Q&A

2026 年世界人工智能大会展现了中国国产 AI 算力演进的哪些新趋势与路径判断，特别是与 2025 年相比有何不同？

2026 年的世界人工智能大会显示，行业竞争已从 2025 年以单卡性能比拼为主，全面进入到超节点（super node）的系统级竞争阶段。中国国产 AI 芯片正通过集群规模、系统设计和工程化能力，走出一条差异化的发展路径。回顾 2025 年的 WAIC，行业关注焦点主要集中在四个方面：推理需求的爆发、AI 应用从聊天机器人向更多场景延伸、华为发布的 384 卡的 CloudMatrix 集群，以及各厂商推出的新一代加速卡。当时的核心是单卡产品迭代与小规模集群验证。到了 2026 年，展会呈现出鲜明的新现象。首先，重磅的单芯片新品发布减少，各家厂商几乎都在展示超节点方案，规模从 64 卡、128 卡机架集群，直至上千卡的训练超节点。与海外厂商如英伟达依赖 NVLink 或 AMD 依赖 UALink 的路线不同，国内厂商的互联技术更多是基于自身技术栈自研的新架构。这背后的核心逻辑在于，国产芯片受限于晶圆制程，单卡算力规格与海外旗舰产品仍有差距。因此，厂商选择在光互联、机架设计、系统级调度等具备强大工程能力和产业配套能力的领域发力，通过扩大集群规模和提升系统利用率，以整体算力输出来满足大模型训练与推理的需求。许多方案采用了无中背板的正交架构，省去了大尺寸背板的制造与良率问题，体现了国产厂商在系统结构创新上的灵活性，例如华为和中兴通讯都在推广此设计。

在 2026 年 WAIC 上，华为发布的 Atlas 950 超节点在技术参数和架构上相较于上一代产品有何具体升级？其他厂商在超节点布局方面又有哪些进展？

华为此次发布的 Atlas 950 超节点，相较于 2025 年发布的由 384 颗升腾 910C 组成的 CloudMatrix，在规模和架构上均有显著升级。新一代超节点将 Scale-Up 域扩展至 1,024 颗升腾 950 DT 芯片，整个系统由 16 个计算机构成，并配备 4 个专用的液冷互联机柜。其整体算力规模达到 1 EFLOPS (FP8)，并通过内存池化技术实现高达 256TB 的总内存。在架构层面，机柜内采用了铜缆和正交背板方案以保证短距离带宽和能效，而机柜间则采用光互联实现长距离扩展，这与上一代 384 卡集群的全光互联方案有所不同。此外，新系统中加入了光路保护机制，当单链路发生故障时不会中断整个系统的运行。这种通信效率和容错能力的提升，对于从百卡向千卡、万卡规模扩展的集群至关重要，直接决定了有效算力的利用率。华为的目标是在这一代超节点产品上实现大参数量国产大模型的训练。除华为外，其他厂商也在积极布局超节点。例如，燧原科技与中兴通讯联合发布了云燧超节点，沐曦与中兴通讯联合推出了曦镜超节点，摩尔线程也展示了自研的 MTT 超节点。目前，64 卡、128 卡的超节点方案已从 2025 年的前沿尝试，发展成为行业标配。

除了超节点方案，本届 WAIC 上还发布了哪些值得关注的 AI 芯片单卡产品？它们分别体现了怎样的技术路线和市场定位？

本届 WAIC 上发布了两款具有代表性的单卡产品，分别体现了通用 GPU 和差异化封装的技术路线。第一款是天数智芯发布的天垓 300，这是一款适配当前行业主流的存算分离架构的国产通用 GPU 产品。该芯片搭载了 144GB 的 HBM3 显存。根据官方实测数据，在 DeepSeek、GLM 等国产大模型上，其推理吞吐量和首个令牌（first token）延迟表现均明显优于英伟达 H100。另一款是东方算星推出的 DF1,000，它代表了通过先进封装突破制程瓶颈的差异化路线。其逻辑芯片采用 14nm 工艺，通过混合键合（hybrid bonding）技术实现了 DRAM 与逻辑 Die 的 3D 堆叠，使得内存带宽达到 6.4TB/s。这条技术路径与华为此前探讨的“陶氏定律”思路相似，即不依赖先进制程来堆砌算力，而是通过架构和封装创新来解决内存墙问题，这被认为是国产芯片未来绕开制程约束的一条重要路径。

从全球视角看，当前云服务厂商的资本支出呈现何种趋势？存储价格上涨在其中扮演了怎样的角色？

当前云服务厂商的资本支出普遍需要大幅上修。以 Google 为例，服务器支出已占其总支出的六成，而这六成中超过一半的增长是由存储价格上涨所驱动。仅考虑涨价因素，就可能占据 2026 年云端资本支出增长的三到四成，这意味着整体资本支出的同比增长幅度至少需达到 70-80%。对于 Google 而言，其资本支出同比增长 100% 也并非不可能，因为该公司在存储采购上愿意支付最高价格，无论是 HBM3e 还是未来的 HPC，并且还在积极采购 TPU 板卡上所需的模拟芯片等其他组件，报价甚至比英伟达高出 40-50%。因此，若 Google 的资本支出增长 100% 并导致自由现金流提前转负，也符合预期。

在当前服务器市场中，CPU 和 GPU 的需求状况如何？英特尔、AMD 及中国本土厂商（如海光）在 CPU 领域的竞争格局呈现出哪些特点？

目前 CPU 和 GPU 的需求都非常强劲。在 CPU 领域，市场呈现出价格与数量两极分化的格局。在价格方面，英特尔是主要的受益者。从 2025 年第三、四季度到 2026 年第一季度，无论是美国还是中国的云服务厂商都在积极向英特尔寻求 CPU 货源，甚至希望签订长期供货协议。然而，英特尔能够供应的 CPU 增量仍然有限。在数量方面，英特尔供应的限制为非英特尔厂商创造了巨大的出货增长机会。美国的 AMD、中国的海光以及其他基于 ARM 架构的 CPU 厂商都实现了高速增长。预计 AMD 在下周的法说会上也将披露其 LTA 情况。中国本土的海光在 CPU 性能上，其高端产品已能对标英特尔第六代服务器 CPU（Granite Rapids），并且在政府加速国产化政策的指导下，其出货量有明显增长。这种 CPU 平台的强劲需求，也带动了内存、内存接口芯片（memory interface）以及基板管理控制器等相关组件的需求，对整个云端半导体产业构成利好。


调研纪要

微信扫码加入星球

知识星球

星球福利

微信扫码
联系客服加入



英伟达在 2027 年的技术路径是怎样的，特别是关于 Kyper 项目和超节点（super-node）架构的规划？这对相关硬件组件的需求会产生什么影响？

根据英伟达 2027 年的技术路径规划，Kyper 项目已不存在。尽管该项目在 ODA（Omniverse Developer Alliance）仍有记录，但公司高层在两周前的 NDR（Non-Deal Roadshow）中已明确表示，因其性能表现不及其他方案，Kyper 项目已被放弃。目前无法确定 2028 年是否会推出 Kyper 这类超级密集型机架（super dense rack）。实际上，英伟达的技术路径正转向与国内厂商类似的超节点（super-node）或多机架（multi-racks）的纵向扩展（scale-up）模式。预计在 2027 年，英伟达将通过 CPU、NPU 或近距离铜连接等方式，实现跨多个机架的超节点纵向扩展。这种架构将显著增加对服务器主板的需求量，同时带动主板上相关组件，如电源、内存和 BMC（基板管理控制器）等的需求增长。国内厂商采用的超节点方案所需的主板数量更多，对产品增量的贡献也相当可观。整体来看，这一趋势对云端半导体（Cloud Semi）行业构成非常有利的格局。

当前存储行业的周期性表现如何？MLC NAND 和 SLC NAND 市场的供需状况及价格走势是怎样的？

当前存储行业面临周期可能见顶的问题。行业分析通常关注三个指标：周期、LTA（长期协议）和 AI 支出。从周期来看，利润价格同比的二阶导数预计在 2026 年 9 月或 10 月达到峰值，这通常会导致股价出现较大波动。LTA 能否进一步重新定价（re-rate）尚存争议。AI 支出虽然持续，但自由现金流提前转负是不可避免的，这与 2025 年同期周期触底、AI 支出刚起步且未签订 LTA 的情况完全不同。因此，预计 2026 年下半年股价将出现大幅波动，可能难以突破前期高点。在细分市场中，MLC NAND 和 SLC NAND 是目前最紧缺的存储产品，其供应量均出现大幅下滑。行业供需缺口预计达到 40%。预计 2026 年下半年，这类传统 NAND（Legacy NAND）的价格每季度至少上涨 50%，甚至可能达到 100%。这与 DRAM 和主流 NAND 市场形成鲜明对比，后者的价格涨幅正在收敛，甚至可能略低于预期。基于此，大中华区唯一仍在生产 MLC NAND 的旺宏电子被认为是最佳的投资标的。预计该公司在第二、三季度的毛利率将大幅提升，甚至不排除在 2026 年第四季至 2027 年第一季达到 80% 至 90% 的毛利率水平。

台积电在法说会上透露了哪些关于先进制程（如 2 纳米和 1.4 纳米）的需求前景和战略布局？这背后反映了哪些市场趋势？

台积电在法说会上指出，2 纳米制程的扩产进度超前于原定时间表，并预言下一代 1.4 纳米制程将成为比 2 纳米规模更大的技术节点。这一判断基于三个前提：首先，AI 的生命周期和云服务资本支出（Cloud Capex）将持续至 2030 年；其次，台积电对其在先进制程领域的市场份额有很高的能见度，认为英特尔的解决方案最多只能与台积电的上一个世代竞争，无法在 1.4 纳米节点上构成威胁；第三，CPU 市场的强劲需求为台积电带来了巨大的外包机遇，除了为 AMD 和 Arm 架构厂商代工 CPU 外，英特尔的服务器 CPU 被视为最后也是最大的外包机会，并有

望在 1.4 纳米节点上由台积电获得。综合来看，AI 半导体的扩张仍在持续。根据最新的成本模型预测，2027 年 AI 半导体市场将增长 60%至 70%，若加上 CPU 业务的贡献，增长率可能接近翻倍。

MediaTek 在 AI ASIC 领域的业务进展和市场地位如何？

MediaTek 在 AI ASIC 领域取得了显著进展，预计其在 2027 年为谷歌 TPU 的出货量至少将达到 300 万颗。同时，在 2 纳米制程的 TPU 项目中，MediaTek 也是一个重要的供应商。从出货量来看，MediaTek 与博通已不相上下，尽管博通因定价较高而在营收份额上占据优势（约 80%）。目前市场对 MediaTek 的预期较低，谷歌在其财报电话会议中特别强调其 TPU 系统的强劲表现，这些利好因素尚未完全反映在 MediaTek 的股价上。

国产大模型（如 Kimi 3、DeepSeek 下一代）的快速发展对国内 AI 硬件和算力芯片公司的需求有何影响？

国产大模型的性能提升将直接驱动国内算力需求的强劲增长，因为模型变得更好用之后，需要更多的算力进行推理。因此，市场对于国产算力芯片公司（如寒武纪、天数智芯）的需求前景普遍持乐观态度。只要这些公司能获得稳定订单并保障产能与供应链，就存在较好的投资机会。关于国产大模型是否会“反卷”到海外市场，目前来看，尽管 Kimi 3 的 token 价格较低，但实际使用 API 接口时其 token 消耗量会增加，导致最终成本与海外模型相差不大。不过，通过蒸馏等技术，国产大模型在性能上确实正在缩小与海外模型的差距。

市场普遍观察到云服务提供商的资本支出在上调，但为何相关硬件或半导体公司的股价并未同步反映这一利好？

尽管 CSP 的 Capex 上调在传统上对硬件供应链是利好，但当前市场反应平淡甚至担忧，主要原因在于此次 Capex 上调很大一部分是由于存储器等组件的价格上涨所致，而非采购量的实质性增加。市场对于因涨价驱动的 Capex 增长持谨慎态度，因为这与增加 GPU 采购或数据中心基础设施建设等对供应链有直接拉动作用的支出性质不同。此外，存储器市场的透明度很高，市场能够轻易计算出有多少 Capex 被用于支付涨价的存储器。尽管业界在存储技术上进行了诸多创新，如 3D 堆叠、存内计算（Computing in Memory）以及高通为边缘计算设计的类 PIM 架构等，试图颠覆传统 DRAM。然而，分析显示，这些新兴市场虽然在未来三到五年内可能增长至 200-300 亿美元的规模，但在整个可能达到万亿美元的存储市场中，占比仅为低个位数。因此，短期内 CSP 仍难以摆脱对 DRAM 的采购依赖，这种进退两难的局面也反映在了相关公司的股价表现上。

长鑫存储的 IPO 计划对中国半导体产业链，特别是设备和国产 AI GPU 领域，会产生哪些中长期的影响？

长鑫存储的 IPO 计划对中国半导体产业链具有积极的中长期影响。在半导体设备（Semi-cap）领域，中国存储厂商的扩张计划将直接利好国产设备商。目前扩张的主要瓶颈在于 ASML 的 DUV 光刻机供应，只要能获得 1980 型号的 DUV 设备，扩产便能顺利进行。光刻环节的突破将带动其他相应国产设备的订单和出货量实现良好增长。在国产 AI GPU 领域，一个强大的本土存储器厂商的支持至关重要。无论是采用存算一体（compute memory）、本地 DDR 堆叠在计算芯片上（local DDR stacking on compute die），还是传统的 HBM 加 CoWoS 封装方案，都需要有力的存储厂商来支持这些技术路线的实现。因此，长鑫存储的壮大将为国产算力的发展提供坚实的中长期支撑。此外，更充足的国产存储供应也有望改变中国智能手机厂商在全球市场因存储短缺而处于的劣势地位。

更多一手调研纪要和海外投行研报数据加V: shuimu2026

更多一手调研纪要和海外投行研报数据加V: shuimu2026